問題(目的)與背景

Prometheus 是一個監控聚合器(Monitoring Aggregator)，它可以處理數以百萬的監控指標、每秒可以處理數十萬的數據點，並將他們集中到一個時間序列(Time-Series)資料庫中，也能夠詳細列出電腦資源。在 nagios 等較舊型的監控系統中，常需要第三方的後台程式協助溝通，而這些第三方程式通常需要複雜的環境配置，也導致擴充能力低下，但 Prometheus 不需要額外的第三方程式協助溝通，因此配置簡單。另外，在 nagios 的警示只有 0 正常、1 警告、2 錯誤、3 未知錯誤這四種狀態提示，而 Prometheus 將所有紀律下來的資料經過資訊處理以後，在內建的 web UI 中以圖形或資料集的方式呈現，也可以配合外部的 GUI 和警示系統，提供偵錯及視覺化警告，提供良好的擴充能力。

Prometheus 在 CAP 中捨棄了 consistency, 因為每個節點是自主的，不同 node 可能有不同檔案，也因此有者去中心化的特點。如果使用情境需要 100% 準確度那 Prometheus 並不適合，但適合以機器為主的監控和監控高度動態的服務導向架構。

架構解析

圖 1 ：Prometheus 官方文檔架構圖

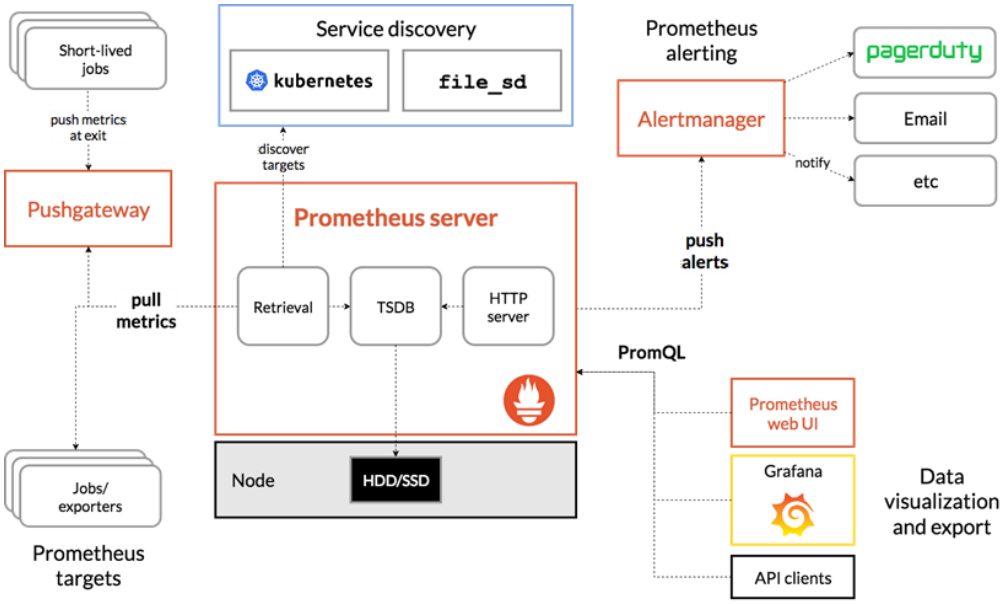

Retrieval system 主要的功能是以 pull 拉取的方式取得指定的監控目標 target 資訊後儲存的模組，定義在 Scrape 模組中，包含三個檔案 manager.go、scrape.go、target.go(圖 2)。每一個目標 target 有一個與之對應的循環 loop，每個 loop 內部執行 Http Get 請求拉取數據。每一個 job 有一個與之對應的 scrape pool，通過一些控制參數，執行周期性數據採集及結束等運作。

圖 2：Retrieval System Class Diagram

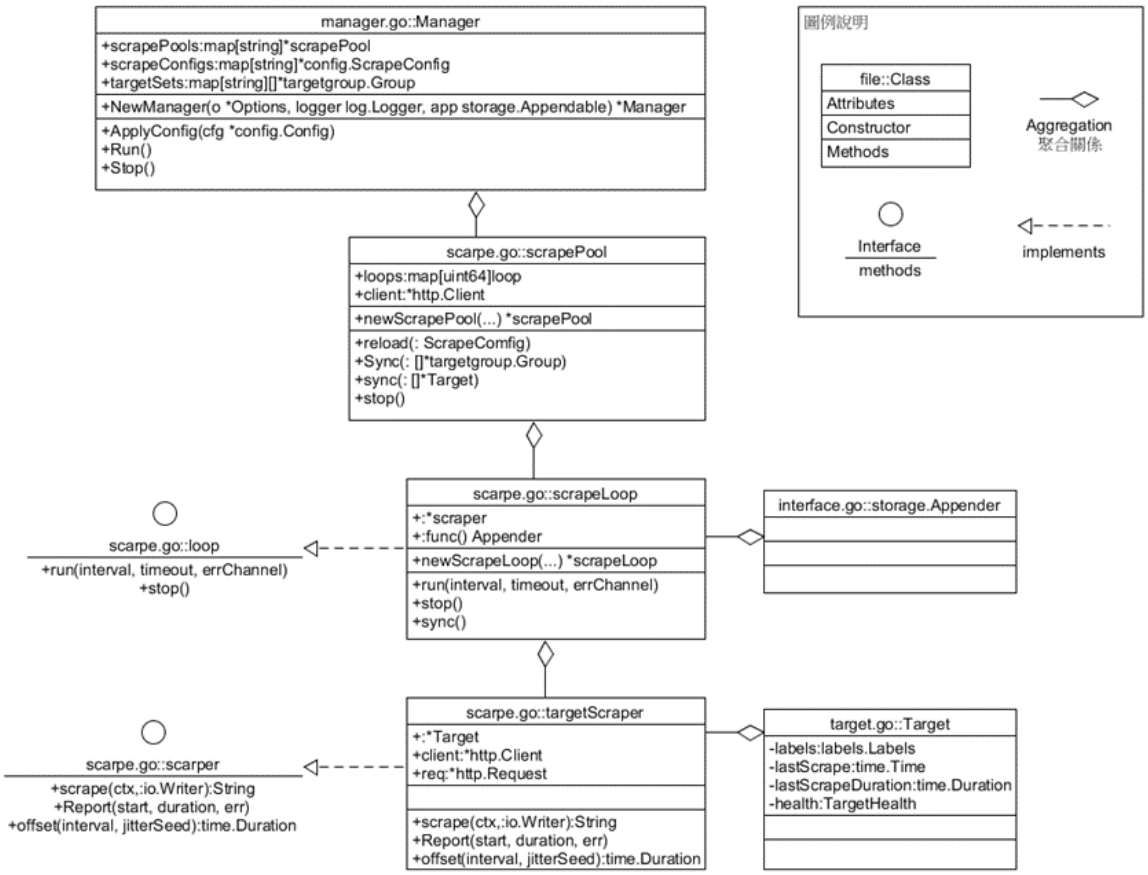

manager.go 包含

Manager 類別:由 discovery manager 取得數據採集目標，記錄在 scrape pools 之中，並負責啟動及停止週期性的資料採集任務。Manager 類別主要的屬性有管理目標資料採集的 scrapePools，採集設定 scrapeConfig，目標集合 targetSets。

ApplyConfig()方法使用新的設定 cfg 重置管理的目標提供者和作業配置。

Run()方法接收並儲存目標集數據更新，並觸發抓取循環來重新加載 reloader()，重新加載為背景執行，不會阻止接收目標數據更新，reload()則為每個 job 建立對應的 scrape pool。

Stop()方法會取消所有正在運行的抓取池和區段，直到完全結束。

scrape.go 包含

scrapePool 類別：管理目標集合的資料採集，主要屬性有執行資料拉取的 loops 以及 Http 端點的 client。

reload()方法使用給定的抓取配置重新加載抓取池，目標狀態被保留，但所有抓取循環都使用新的抓取配置重新啟動。

Sync(tgs []*targetgroup.Group)方法將目標群組轉換為實際的抓取目標，將當前運行的抓取器與結果集同步，並傳回所有抓取和刪除的目標。

sync(targets []*Target)方法對一個目標列表進行同步處裡，新目標啟動抓取循環，失效的目標則停止抓取循環。

stop()方法終止所有抓取循環。

scrapeLoop 類別：實作 loop 介面的資料拉取循環物件，可以進行啟動 run()及停止 stop()呼叫，停止後不得重複使用。主要屬性有拉取資料的 Scraper 以及附加器 Appender。

targetScraper 類別：實作 scraper 介面的目標拉取物件，以 Http Get 執行請求，呼叫 scarpe()抓取資料，Report()回報資料，offset()時間偏移量設置。

target.go 包含

Target 類別代表單一 HTTP 或 HTTPS 的端點。

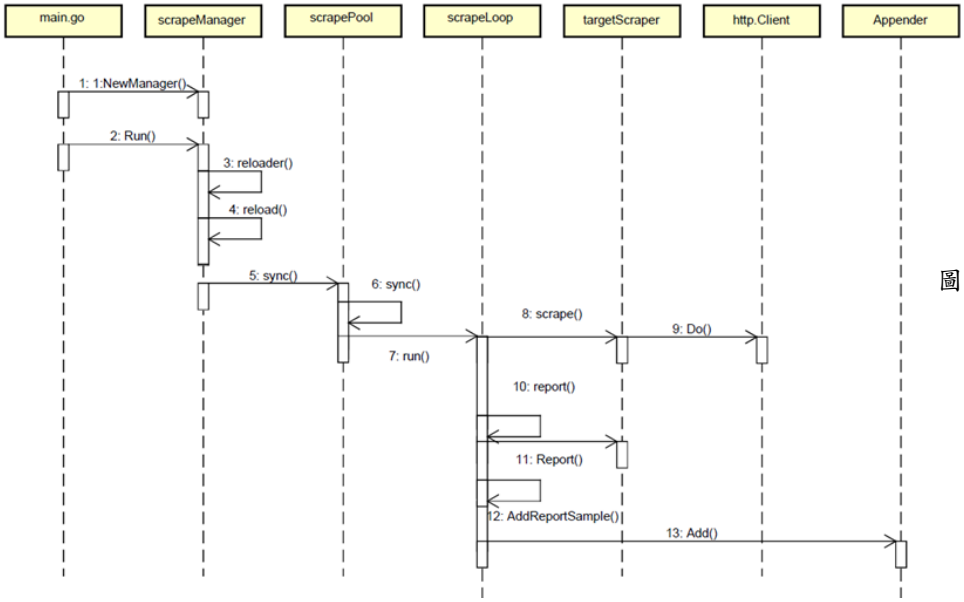

圖 3：Scrape Sequence Diagram

Scrape 時序圖(圖 3)分析

1. main.go 中使用 scape.NewManager 建立 ScrapeManager，ScapeManager 中使用 Map 結構來儲存管理目標資料採集的 scrapePools, 採集配置 scrapeConfig，目標集合 targetSets；Prometheus 中，將一個獨立的數據來源（target）稱之爲 instance。包含相同類型的 instance 的集合稱之爲 job，Manager 中 ApplyConfig 可抓取配置，使用 job 爲 key 查詢 scrapeConfig Map 結構，若 job 不存在，從 ScrapePool 中刪除，若配置被更改，清理歷史配置，啟動 reload 將新配置至 ScrapePool。
2. 建立 ScrapeManager 之後，main.go 呼叫 scrapeManager.Run()以啟動 ScrapeManager，Run()方法中先執行 reloader()加載 targets，targets 更新時會觸發 reload()，加載完成後呼叫 Sync()將當前的抓取器與結果集同步。
3. Manager 的 reloader()方法用來加載 targets，reloader 的加載發生為背景執行，不會影響 target 的更新。
4. Manager 的 reload() 執行重新加載，爲 targets 集合中每一個 target 資料來源生成一個對應的 scrape pool 來管理其運作，由 targetSets 中取得所有的 Job，若處理 Job 的對應 scarpe pool 不存在於 Scrape_pools 之中，則讀取 Job 對應的 scrape config 配置以建立 scrape pool，並將其儲存於 Scrape_pools Map 之中，為提高效率，此流程採並行運行，需先用

sync.Mutex 鎖定，遍歷 TargetGroup 將所有 scrape pool 創建完成後釋放鎖，並等待其他並行工作運行完成。

5. 呼叫 Scrape Pool 的 Sync()方法，會將當前運行的抓取器與 All 集合同步，sync.Mutex 鎖定後，遍歷所有 TargetSet 群組中的 Target，有效的 Target 加入 All 集合，無效的 Target 加入 droppedTargets 集合，接著呼叫 sync()方法將 All 集合中 Target 轉換為實際的抓取器。
6. Scrape Pool 的 sync()方法所取得的 Target 的列表 all 可能重複，需將重複刪除，並為新目標啟動抓取循環，並為消失的目標停止抓取循環。完成後對每一個不重複的 Scrape Loop 呼叫 run() 方法執行抓取循環。
7. Scrape Loop 的 run() 方法執行抓取循環，依據每個 Scrape Loop 定義的時間週期，定期呼叫 scrapeAndReport()方法執行抓取。scrapeAndReport()方法會執行抓取，依序觸發執行 targetScraper 的 scrape()方法、http:Clinet 的 Do()方法、ScrapeLoop 的 report()方法。然後將結果與報告指標附加記錄到附加器 Appender 的末端。抓取動作可能使用到一個以上的 Appender，Scrape Loop 會盡可能使用較少的 appender。
8. targetScraper 的 scrape()方法透過 HTTP Get 請求來抓取數據，先建立 HTTP Request 請求物件，設定適當請求標頭，透過 http:Clinet 的 Do()方法來發起請求。
9. 執行 http:Clinet 的 Do()方法，傳回抓取資訊。
10. ScrapeLoop 的 report()方法會呼叫 targetScraper 的 Report()方法抓取的訊息，並針對結果使用 addReportSample()方法做處理或錯誤回報。
11. 執行 targetScraper 的 Report()方法，回報關於最後一次抓取的目標數據
12. addReportSample()方法呼叫 Appender Add()方法將資料寫入儲存體。
13. 執行 Appender Add()方法，storage.Appender 針對存儲體提供資料批次附加的邏輯。必須通過調用 Commit 或 Rollback 來完成，之後不得重用。

Service Discovery(服務發現，SD)

若監控的目標時常改變，則每次都需修改靜態配置後再進行 reload，為了避免這種情況，Prometheus 開發了動態發現(Service Discovery, SD)，能感知目標的 CRUD 後自動 reload，而不需重新配置再重啟 server。與 SD 相關的資訊傳遞至 discovery manager，然後 discovery manager 會和 SD 系統進行通訊，當使用者下達 reload handler 的指令時，會調用 reloadConfig ，並依次調用相關 function [1][2][3] (圖 4)。但當 SD 的配置進行改動時(例如新增 job)，prometheus 還是需要手動 reload 配置文件並重啟 server。

---

[1] https://github.com/prometheus/prometheus/blob/063319087c122b3b296cc630d93f577dac31fd1c/cmd/prometheus/main.go#L874-L909

[2] https://github.com/prometheus/prometheus/blob/063319087c122b3b296cc630d93f577dac31fd1c/cmd/prometheus/main.go#L1159-L1201

[3] https://github.com/prometheus/prometheus/blob/063319087c122b3b296cc630d93f577dac31fd1c/cmd/prometheus/main.go#L662-L748

圖 4：Service Discovery Sequence Diagram

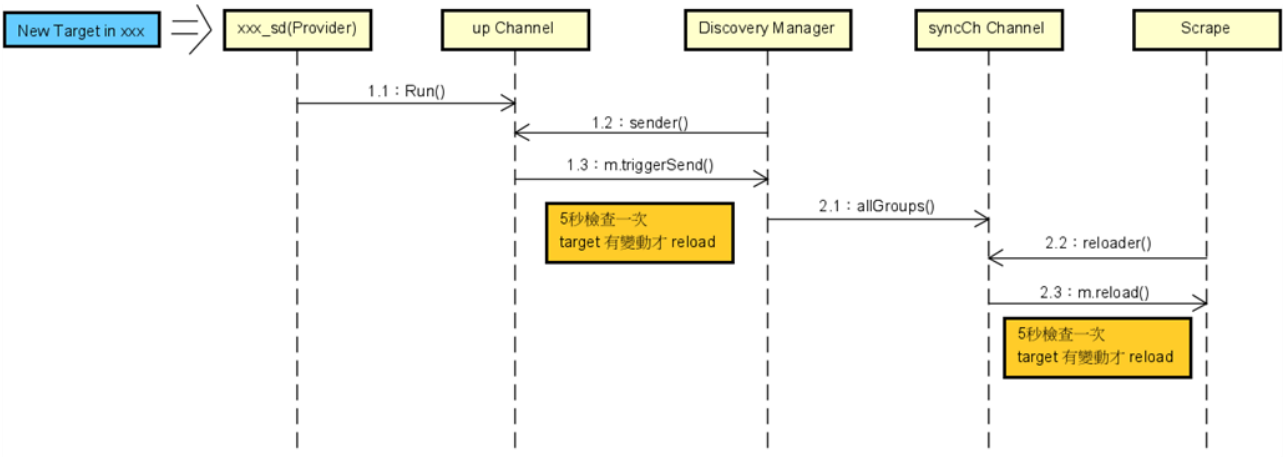

SD 機制的目的是發現 provider(e.g. DNS, Azure, Kubernetes)的 target 並最終將資訊提供給 Prometheus 監控。SD 的 Discoverer 介面(圖 5)提供給各 Provider 介接[4]，最開始會調用 Run()(圖 6)將監控的 target group 發送至 up channel，再用 init()的 discovery.RegisterConfig(圖 7)進行註冊，接著可能將整組或是有更動(視 provider 而定)的 target group 透過 up chan 發送給 discovery Manager 處理。

```go
// in prometheus/discovery/discovery.go
type Discoverer interface {
    Run(ctx context.Context, up chan<- []*targetgroup.Group)
}
```

圖 5：Discoverer Interface

```go
// in prometheus/discovery/manager.go
func (sd *StaticProvider) Run(ctx context.Context, ch chan<- []*targetgroup.Group) {
    ……
    case ch <- sd.TargetGroups:     // 將target group發送至channel
    ……
}
```

圖 6：Run()本體

```go
// prometheus/discovery/kubernetes/kubernetes.go
func init() {
    discovery.RegisterConfig(&SDConfig{})
    ……
}
```

圖 7：init()內的 discovery.RegisterConfig

Group(圖 8)是一群 target 的 list，其擁有共同的 LabelSet，LabelSet 是一組名稱與值的 map [5]

```go
// in prometheus/discovery/targetgroup/targetgroup.go
type Group struct {
    // Targets為主要標籤。e.g. {"__address__": "localhost:9090"}
        Targets []model.LabelSet
    // Label為次要標籤，唯一，可為空。e.g.{"foo": "bar", "bar": "baz"}
        Labels model.LabelSet
    // Source用以描述Group，唯一。e.g. "<source>"
        Source string
    }
```

圖 8：Group struct

[4] https://github.com/prometheus/prometheus/tree/main/discovery
[5] https://github.com/prometheus/common/blob/840c039c5fcce8204ed656bd75b084d2e9d80c1d/model/labelset.go#L28

Discovery Manager

Manager(圖 9)會處理由 up Chan 送來的資料(監聽與獲取資料方式與 scrape 處理 sync Chan 雷同，故此略)，並透過 poolKey(對應配置文件的 job name)和 provider 快速找到對應的 target group 陣列。

```
// in prometheus/discovery/manager.go
type Manager struct {
    ……
    targets    map[poolKey]map[string]*targetgroup.Group    // 發現的Targets
    providers []*provider   // 持續監聽provider
// 把發現的Targets透過channel傳遞給scrapeManager
    syncCh chan map[string][]*targetgroup.Group
    ……
}
```

圖 9：Manager

如此在 discovery manager 裡就可以拿到所有 targets 的資訊，接著 discovery manager 透過 allGroups() [6]傳入 syncCh，scrape manager 會持續監聽 syncCh，一旦有新 message 傳入，scrape 就會 reload 變動的 target group(圖 10)，之後 scrape 就會開始 pull target 進入 TSDB。

```
// in prometheus/scrape/manager.go
func (m *Manager) Run(tsets <-chan map[string][]*targetgroup.Group) error {
    go m.reloader()
    ……
        // 透過syncCh獲取被監控的targets資料
        case ts := <-tsets:
            m.updateTsets(ts)   // 將targets存儲到scrapeManager.targetSets
            // 若有targets更動，發送至m.triggerReload並觸發reloader
            select {
            case m.triggerReload <- struct{}{}:
            ……
}
```

圖 10：scrape 監聽 syncCh

每 5s 監聽 m.triggerReload 信號，執行 m.reload() [7]加載 targets(圖 11)。

```
// in prometheus/scrape/manager.go
func (m *Manager) reloader() {
    ticker := time.NewTicker(5 * time.Second)   // 5s計時器
        ……
        // 若Manager裡有targets更動，會向m. triggerReload寫入值
        // reloader每5秒觀察m.triggerReload是否有值，有則觸發m.reload()
        case <-ticker.C:
            select {
            case <-m.triggerReload:
                m.reload()
            }
        ……
}
```

圖 11：Manager

TSDB

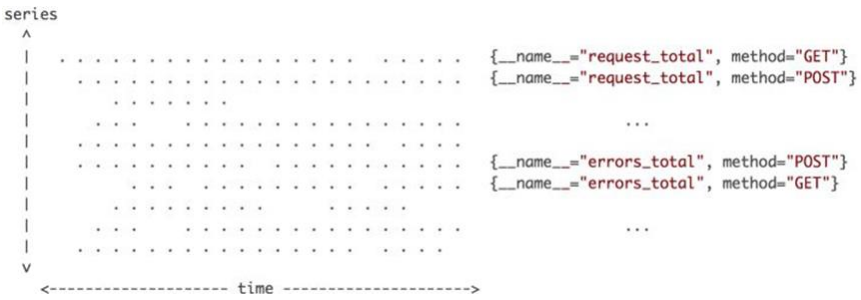

圖 12：series 紀錄

[6] https://github.com/prometheus/prometheus/blob/6555cc68caf8d8f323056e497ae7bb1e32a81667/discovery/manager.go#L381-L399

[7] https://github.com/prometheus/prometheus/blob/063319087c122b3b296cc630d93f577dac31fd1c/scrape/manager.go#L188-L216

圖 13：數據點加入 series

```
// 第一個點時戳和值都直接加入
if num == 0 {
    ...
// 第二個點時戳直接加入，值做XOR壓縮
} else if num == 1 {
    tDelta = uint64(t - a.t)
    ...
    a.writeVDelta(v)
// 時戳做DoD壓縮直接加入，值做XOR壓縮
} else {
    tDelta = uint64(t - a.t)
    dod := int64(tDelta - a.tDelta)
    // 根據dod有不同寫入方式
    switch {
        ...
    }
    a.writeVDelta(v)
}
// 紀錄資訊供下次使用
...
}
```

在 tsdb 中，同一時間會有多個 series 監控紀錄指定資源，一個 series 由數據點的 list 和 label 的 list 組成。數據點由一個時戳和一個值組成，而 label 為一 key-value pair。將一個新的數據點加入 series，而在加入時會先將時戳和值分別用 DoD 壓縮和 XOR 壓縮再加到 series 內(圖 13)。因為 tsdb 有以下特性，一、相鄰數據點的時戳差距變化， 即使有浮動也僅在小範圍內(採樣間隔固定)；二、 相鄰數據點的 value 變化也很小，甚至有相當比例為 0。因此採用此種壓縮能有效壓縮 series 的大小。

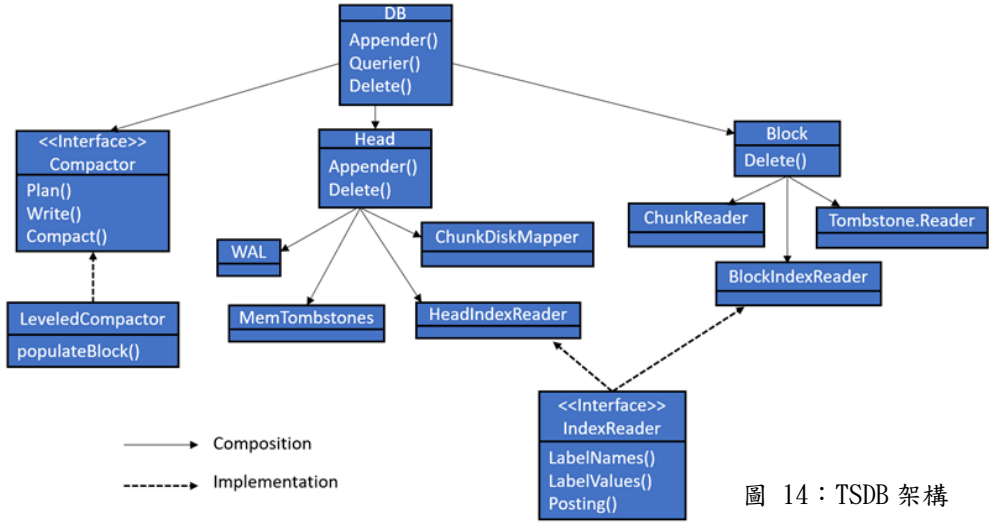

圖 14：TSDB 架構

整個 DB(圖 14)採用類似 LSM algorithm(Log Structured Merge-tree)，主要由 Head, Block, Compactor(圖 15)物件組成。Head 指的是正在寫入的 block，儲存在 memory 中，且因為在 tsdb 中有「越近期資料，越容易被查找」的特性，因此僅將 Head 存進 memory 既能減少空間也能加快查訪速度；Block 是已經持久化且無法更動(immutable)的 block。不管是 head 或是 block，都以更小的 chunk 為單位保存在 disk。

```
// in tsdb/compactor.go
type Compactor interface {
    // 回傳要壓縮的blocks
    Plan(dir string) ([]string, error)

    // 將block寫入資料夾
    Write(dest string, b BlockReader, mint, maxt int64, parent *BlockMeta) (ulid.ULID, error)

    // 將Plan()回傳的結果進行壓縮
    Compact(dest string, dirs []string, open []*Block) (ulid.ULID, error)
}
```

圖 15：Compactor Interface

建立資料時，為避免資料因為意外崩潰導致數據丟失，除了經過前述壓縮後寫進 head block，也會將未壓縮的資料寫入至預寫式日誌(Write-ahead

Logging)中。當寫入 head block 超過寫入時間時，會將其持久化成一個 level 0 block；當同一 level 的 block 夠多，Compactor 就會壓縮成 level 更高的 block。

讀取時，BlockQuerier 根據不同結構產生 headIndexReader 或是 blockIndexReader(圖 16)，index 是倒序索引(inverted index)的資料結構，將給定的 label name 映射到目標所在 chunk 的 offset，減少查找所需時間。

```go
// in tsdb/block.go
// IndexReader provides reading access of serialized index data.
type IndexReader interface {
    // 回傳index內全部的label name(key)
    LabelNames(matchers ...*labels.Matcher) ([]string, error)

    // 給定label names，回傳對應values
    LabelValues(name string, matchers ...*labels.Matcher) ([]string, error)

    // 給定label names和values，回傳對應Posting，Posting包含series的offsets
    Postings(name string, values ...string) (index.Postings, error)
    ...
}
```

圖 16：IndexReader Interface

更新資料時，若目標在 block 中，因為 block 無法做更動，所以只能寫在 head，在讀取時會以新的為主，而壓縮 block 時若有對同一資料進行寫入，會只有新的資料寫入至壓縮後的 block。

刪除資料時，刪除紀錄會保存在目標所擁有的 tombstone files(圖 17)，而非立即從 block 刪除。當整個 block 的資料都超過保留時間後，整個 block 就會被丟棄。

```go
// in tsdb/tombstones/tombstones.go
// Stone holds the information on the posting and time-range
// that is deleted.
type Stone struct {
    Ref       storage.SeriesRef
    Intervals Intervals
}
```

圖 17：Stone struct

此設計如何解決問題(簡單擴充、大量資料集、資料模組化)

為了可以觀察監控時的數據，使其不再是黑箱作業，以及簡單的提供網路大範圍監控，採用了 exporter 和 pull 的機制，先在需要被監控的機器上安裝好 exporter，接著在 server 端進行 pull，就可以達到簡單的高可擴充性和避免傳統 push 方法，需要耗費大量資源去聯繫每個 client 的缺點，並且使用 metric 和 tsdb 來將資料整合，使用 metric 能夠讓資料模組化，因而更好的使用圖形或資料集的方式呈現，而 tsdb 則讓資料能夠更長時間的存在磁碟當中，並且使資料擁有時間性。

技術實作

這次小實作採用的是 windows 系統的 server，因為還在期中，所以我們還沒對 prometheus 的深度用法進行了解，像是 docker、API 等等的用法。
Windows 的 server 架設非常簡單，直接到官方網站下載 server 的 exe 檔案就可以了，打開後他會執行 server，預設的位址會是 http://localhost:9090，這代表 prometheus 會定時抓取 local 端的資源進行紀錄，抓取時間預設為 15s 抓取一次，如果想要更改 port 或是抓取資料的間隔，可以在 prometheus.yml 這個檔案中更改 scrape_interval: 15s 和- targets: ["localhost:9090"]。

```
# my global config
global:
  scrape_interval: 15s # Set the scrape interval to every 15 seconds. Default is every 1 minute.
  evaluation_interval: 15s # Evaluate rules every 15 seconds. The default is every 1 minute.
  # scrape_timeout is set to the global default (10s).
```

```
scrape_configs:
  # The job name is added as a label `job=<job_name>` to any timeseries scraped from this config.
  - job_name: "prometheus"

    # metrics_path defaults to '/metrics'
    # scheme defaults to 'http'.

    static_configs:
      - targets: ["localhost:9090"]
```

Server 架設好之後，就可以連上 http://localhost:9090 去做查詢，prometheus 的查詢方法是使用他們創建好的 API 叫做 promql，因為 prometheus 有網頁的 UI 介面，所以可以直接在搜尋欄中使用 promql 選擇我們想要查詢的東西，如果對網頁通訊比較熟悉的使用者，也可以直接使用網址來做搜尋。
這裡以 prometheus_target_interval_length_seconds 為例子，輸入完呈現這樣

按下執行後，下方就會呈現出本地端電腦的資源

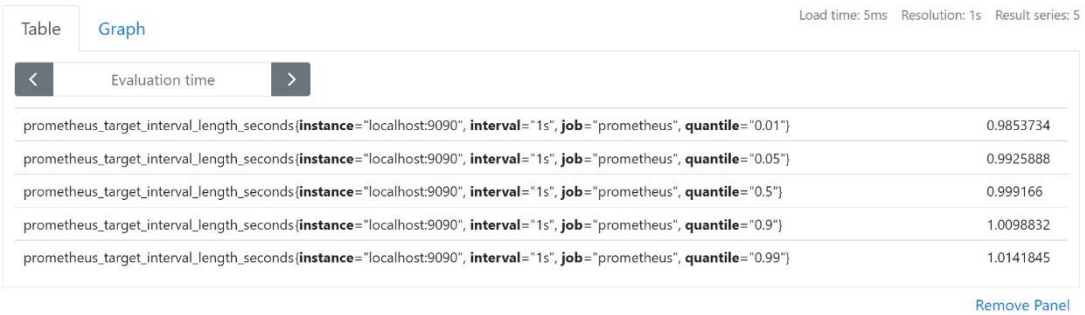

附上網址的差異(前&後)

localhost:9090/graph?g0.expr=&g0.tab=0&g0.stacked=0&g0.show_exemplars=0&g0.range_input=1h

localhost:9090/graph?g0.expr=prometheus_target_interval_length_seconds&g0.tab=1&g0.stacked=0&g0.show_exemplars=0&g0.range_input=5m

心得

老實說 prometheus 的 server 真的非常簡單，能查詢的東西也非常多，在 promql 裡就有很多像是 cpu_time、http_request_total 等等，還可以運用 promql 來選擇要查詢的區間，像是瞬時、區間、純量等等，除此之外，prometheus 還提供了 GUI 介面，可以讓使用者看出資料的分布情形。

評論

Pros

- base-PULL，無須安裝代理。
- Prometheus 只要添加 label 就能輕易抓取 K8S cluster(其可用於部署和管理多機器內的多個 container)的指標。
- 支援許多客戶端 library 和第三方 Exporter。
- 針對單節點儲存使其操作簡單。
- 可視化和監控警報對使用者很友善。
- 可以詳細列出電腦資源的遠端監控系統，擁有部署簡單、去中心化的特點，配合外部的 GUI 和警示系統，提供偵錯及視覺化警告。

Cons

- 內建的 query 採用 PromQL 語言，其需綁定 Grafana，需要額外進行 Grafana[8]的設置。
- 不支援 clustered storage，對於監控指標的數量有先天限制。
- 監控系統的通病，CAP 中的可用性(availability)優先於一致性(consistency)，可能導致部分副本數據丟失。
- 可擴展性(scalability)差，不適合儲存龐大或長期資料[9]，大規模使用需要第三方 component(e.g. Thanos, Cortex, etc.)才能實現[10]，這些第三方 component 也都有各自的問題(不展開討論)。
- 儲存指標而非儲存 log，需要第三方的 log 傳送和分析工具才能保存 log(e.g. Loki, ELK stack, etc.)。

結語

[8] https://grafana.com/
[9] https://prometheus.io/docs/prometheus/latest/storage/
[10] https://www.youtube.com/watch?v=3pTG_N8yGSU